GOBIERNO DE MÉXICO | Educación
Secretaría de Educación Pública

TECNOLÓGICO NACIONAL DE MÉXICO

Instituto Tecnológico de Aguascalientes

MAESTRÍA PROFESIONALIZANTE EN INTELIGENCIA ARTIFICIAL

Instituto Tecnológico de Aguascalientes

Departamento de Sistemas y Computación

Visualización de datos

Fundamentos de visualización de datos

Avance de proyecto

Autor: Javier Adrián Muñoz Molina

Octubre 2026

Introducción

El análisis exploratorio de datos (EDA) permite identificar patrones, tendencias y posibles relaciones entre variables mediante técnicas de estadística descriptiva y visualización.

El objetivo es analizar la distribución espacial de los objetos identificados en las imágenes y explorar las diferencias entre categorías y tamaños. Para ello, se consideran variables como la posición horizontal y vertical normalizada, el área relativa de los objetos y su categoría. A partir de estas variables se construyen visualización univariadas, bivariadas, multivariadas y comparativas, seleccionadas de acuerdo con el tipo de dato y la pregunta analítica que se busca responder

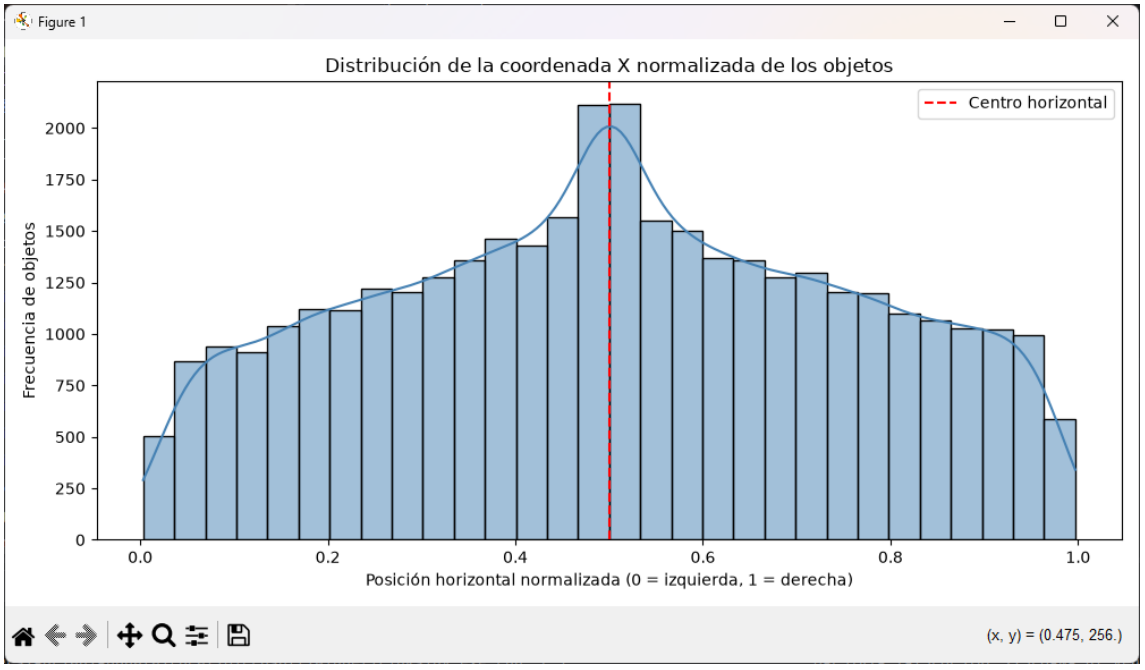
Contexto

Pregunta analítica ajustada: ¿En que zonas de las imágenes se concentran las diferentes categorías de objetos y qué patrones de distribución presentan?

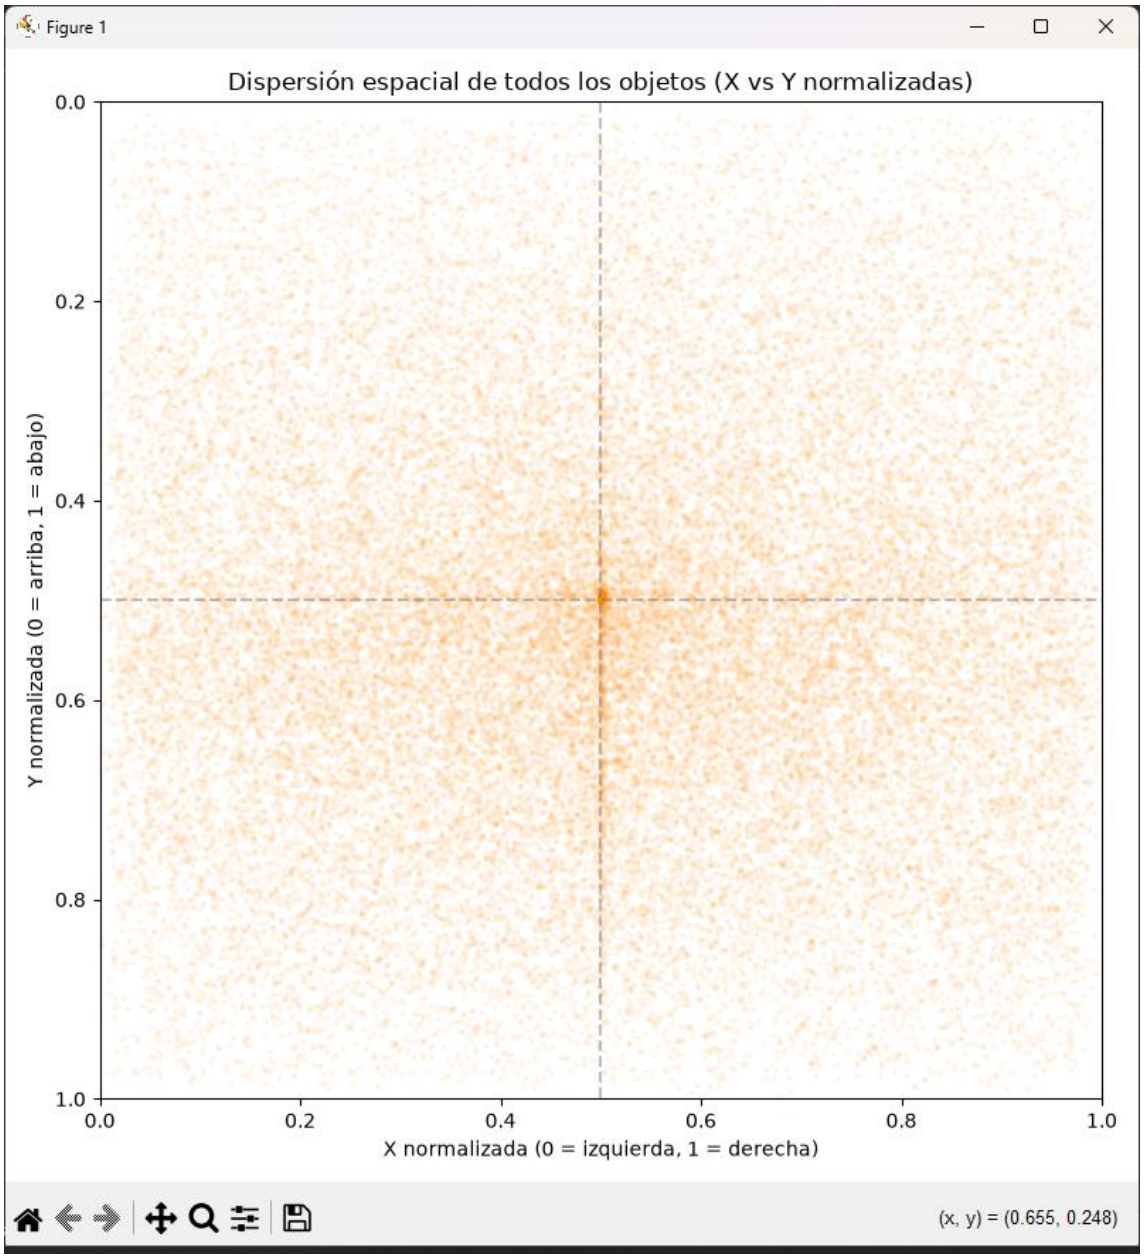
Variable	Tipo de dato
Categoría del objeto	Cualitativa nominal
Identificador de imagen	Identificador
Coordenada X	Cuantitativa continua
Coordenada Y	Cuantitativa continua
Ancho del objeto	Cuantitativa continua
Área del objeto	Cuantitativa continua
Número de objetos por imagen	Cuantitativa discreta derivada
Ancho de imagen	Cuantitativa discreta
Alto de imagen	Cuantitativa discreta

Exploración de datos (EDA) con visualizaciones

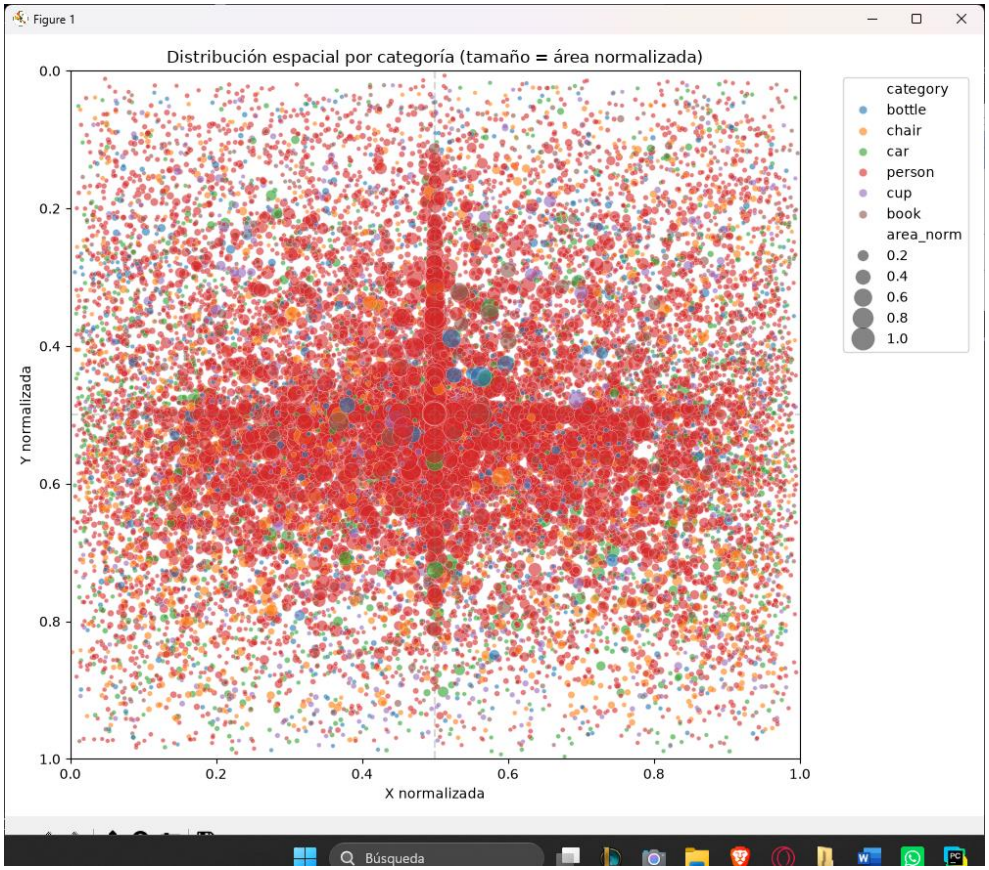
Visualización 1 – Univariada: Distribución de la coordenada X normalizada



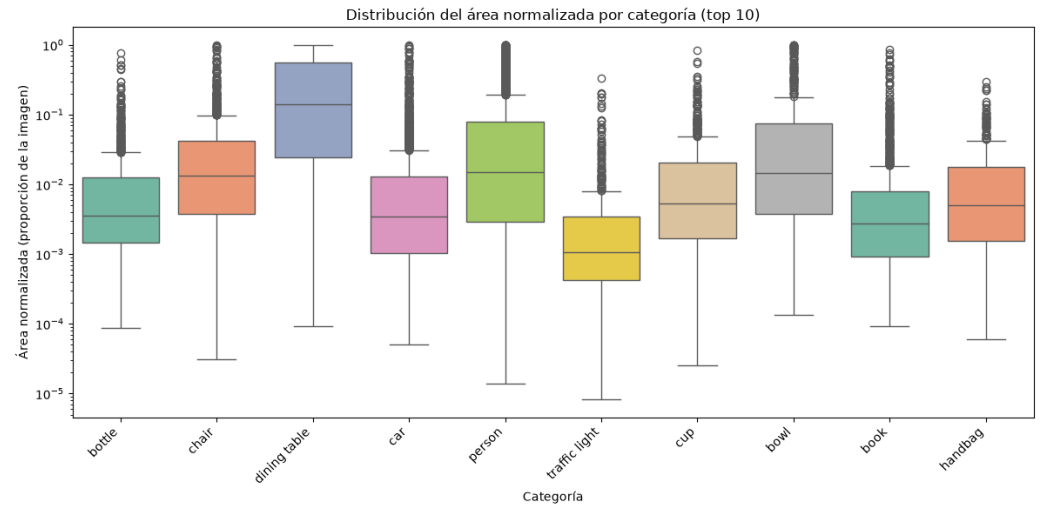
Visualización 2 – Bivariada: Dispersión espacial X vs Y



Visualización 3 – Multivariada: Dispersión X vs Y con color por categoría y tamaño por área



Visualización 4 – Distribución / comparación de grupos: Boxplot de área normalizada por categoría



Visualización temporal o geospacial

No aplica. COCO 2017 no incluye variables de fecha/hora ni coordenadas geográficas.

2. Matriz de decisión

Visualización	Variables involucradas y tipo de dato	Pregunta que responde	Técnica elegida	Justificación de elección	Alternativas descartadas y por qué
Histograma de x normalizada	X normalizada (cuantitativa continua)	¿Cómo se distribuyen horizontalmente los objetos en las imágenes?	Histograma con KDE	Permite ver la forma de la distribución (sesgo, modas) de una variable continua y detectar zonas de concentración horizontal.	Se descartó un gráfico de barras porque X es continua y requiere agrupación en intervalos; el histograma es la técnica estándar para ello. También se descartó un boxplot porque no muestra la forma completa de la distribución.
2. Dispersión X vs Y	X normalizada (continua) y Y normalizada (continua)	¿En qué zonas (combinación horizontal – vertical) se concentran los objetos?	Scatter plot con transparencia	Excelente para mostrar la relación entre dos variables continuas y revelar patrones de concentración espacial (clusters, zonas vacías). La transparencia permite manejar la alta densidad de puntos.	Se descartó un heatmap 2D porque, aunque también muestra densidad, el scatter permite ver la dispersión individual y es más directo para identificar zonas. Se

					descartó un gráfico de líneas porque no hay una relación funcional entre X e Y.
3. Dispersión X vs Y con color y tamaño	X (continua), Y (continua), Categoría (nominal), Área normalizada (continua)	¿Cómo varía la distribución espacial según la categoría y el tamaño del objeto?	Scatter plot multivariado (color y tamaño)	Incorpora multiples variables simultáneamente. El color (categórico) permite comparar categorías y el tamaño (cuantitativo) añade la dimensión de área. Es eficaz para detectar si ciertas categorías ocupan zonas específicas y si los objetos grandes se ubican en el centro.	Se descartaron small multiples porque, aunque son válidas, requieren más espacio y dificultan la comparación directa entre categorías en una sola vista. Se descartó un gráfico de burbujas 3D porque la tercera dimensión (profundidad) es difícil de percibir con precisión.
4. Boxplot de área por categoría	Área normalizada (continua) y Categoría (nominal)	¿Cómo se distribuye el tamaño de los objetos según su categoría? ¿Qué categorías son más variables?	Boxplot con escala logarítmica	Compara grupos (categorías) en una variable continua, mostrando mediana, cuartiles y valores atípicos. La escala logarítmica es necesaria por la gran variabilidad del área.	Se descartó un violin plot porque, aunque muestra la densidad, el boxplot es más claro para comparar medianas y cuartiles entre muchas

				Es ideal para evaluar dispersión y diferencias entre grupos.	categorías. Se descartó un gráfico de barras con medias porque oculta la variabilidad y los valores extremos.
Temporal / geoespacial	—	—	—	No aplica: COCO 2017 no contiene variables de tiempo ni ubicación geográfica.	No se consideraron alternativas porque las variables no existen en el dataset.

3 . Hallazgos preliminares

El diagrama de dispersión multivariado permite explorar diferencias en la ubicación de los objetos según su categoría, a partir de la visualización parece que algunas categorías, como persona y automóvil, presentan una distribución espacial mas amplia, mientras que otras como silla, botella y taza, muestran una mayor concentración en diversas zonas.

Ademes el diagrama de cajas permite comparar la distribución del área normalizada entre categorías. Las diferencias en las medianas, los rangos intercuartílicos y los valores extremos ayudan a identificar que categoría presentan mayor variabilidad en el tamaño de sus objetos.

La distribución de las anotaciones presenta diferencias en la frecuencia de aparición de las categorías, con una mayor representación de algunas clases, como persona.

Conclusión

El análisis exploratorio de COCO 2017 permite examinar la distribución espacial de los objetos y comparar sus características según la categoría a la que pertenecen. Las visualizaciones utilizadas ofrecen perspectivas complementarias: el histograma permite estudiar la distribución horizontal, el diagrama de dispersión facilita la identificación de concentraciones espaciales, la visualización multivariada permite explorar diferencias entre categorías y el diagrama de cajas ayuda a comparar la distribución del área normalizada.

Entre los hallazgos preliminares se encuentra una posible concentración de objetos hacia la zona central de las imágenes, además de diferencias aparentes en la distribución espacial y el tamaño de ciertas categorías. También se identifican diferencias en la frecuencia de aparición de las clases, aspecto que debe tenerse en cuenta para evitar interpretaciones generales que no representen por igual a todas las categorías.

Estos resultados constituyen una primera aproximación exploratoria y no demuestran por sí solos que los patrones observados sean estadísticamente significativos.

Fuentes de información

COCO 2017 Dataset. (s. f.). Kaggle. https://www.kaggle.com/datasets/awsaf49/coco-2017-dataset
NumPY Documentation. (s. f.). https://numpy.org/doc/
pandas documentation — pandas 3.0.6 documentation. (s. f.). https://pandas.pydata.org/docs/
Tt2.pptx | Genially. (2026, 25 septiembre). Genially. https://view.genially.com/6ab1f7236db6f437e78d4a38